

CENTRO DE ENSEÑANZA TÉCNICA Y SUPERIOR



Materia:

Aplicaciones de Minería de Datos

Actividad:

Extendiendo el Modelo Multidimensional

Profesor:

MIGUEL GONZALEZ MARQUEZ

Alumno:

Juan Manuel Sandoval Ramirez - e012602

Fecha de entrega: Martes 22 de Septiembre de 2026

En la clase de hoy demostramos cómo 3 variables simples (Edad, Salario, Engagement) se convierten en un vector tridimensional. Pero en las aplicaciones modernas de Minería de Datos y *Machine Learning*, rara vez trabajamos con columnas tan sencillas.

Para nuestra próxima sesión, investiguen de manera técnica ¿cómo se mapean los siguientes tipos de datos complejos dentro de un **Modelo Multidimensional** y qué problema matemático enfrentamos al hacerlo:

El Espacio Vectorial de las Imágenes: Si queremos que una red neuronal analice una imagen a color (RGB) de 256x256 píxeles, ¿cómo se representa esto matemáticamente en un arreglo multidimensional (Tensor)? ¿Cuál sería el valor de p (número de dimensiones) para una sola imagen?

Se representa por medio de un tensor el cual es básicamente una matriz 3d, en este caso una dimensión para la altura, otra para el ancho y otra para el valor en R, G y B respectivamente y para los valores de p es simplemente una combinación de estos tres ($3 \times 256 \times 256 = 196608$)

El Espacio Vectorial del Texto (*Word Embeddings* / TF-IDF): Un algoritmo no puede calcular la distancia euclidiana entre la palabra "Feliz" y "Triste". Investiga brevemente cómo el Procesamiento de Lenguaje Natural convierte palabras u oraciones completas en vectores numéricos dentro del modelo multidimensional.

Para analizar palabras, se utilizan técnicas que contabilizan que tan dispersas son las palabras en un conjunto de oraciones, y se califican de esta manera, también hay otros que se dedican a mostrar un vector de similitud basado en que otras oraciones tienen palabras similares, pudiendo hacer asociaciones de “esta palabra” se acerca mucho a esta otra”

La Maldición de la Dimensionalidad (*The Curse of Dimensionality*): De acuerdo a los conceptos de estadística y algoritmos basados en distancias (como se aborda en ISLP), ¿qué le ocurre geoméricamente a la distancia entre los usuarios en la matriz $\mathbf{X}$ cuando el número de dimensiones (p) crece a miles o millones?

Lo que pasa es que geoméricamente los valores se van hacia las esquinas o bordes y dejan mucho espacio blanco, también ocurre que para muchos valores, el modelo no puede diferenciar si la distancia entre los puntos es grande o es corta.

Referencias:

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.
<http://www.deeplearningbook.org/>

Jurafsky, D., & Martin, J. H. (2024). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition* (3.^a ed. borrador). Stanford University. <https://web.stanford.edu/~jurafsky/slp3/>

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer.
<https://doi.org/10.1007/978-3-031-38747-0>