

Binary Encoding

1. Integer Mapping:

- 'Laptop': 1
- 'Tablet': 2
- 'Phone': 3
- 'Desktop': 4

- 'Laptop': 0 -> 00
- 'Tablet': 1 -> 01
- 'Phone': 2 -> 10
- 'Desktop': 3 -> 11


- 'Laptop': 1 -> 001
- 'Tablet': 2 -> 010
- 'Phone': 3 -> 011
- 'Desktop': 4 -> 100

Original	Integer	Binary	DeviceType_bin_0	DeviceType_bin_1	DeviceType_bin_2
'Laptop'	1	001	0	0	1
'Tablet'	2	010	0	1	0
'Phone'	3	011	0	1	1
'Desktop'	4	100	1	0	0
'TV'	5	101	1	0	1

Instead of 5 columns (like One-Hot Encoding), we now have only 3 numerical columns representing the **DeviceType**. For a feature with 100 unique categories, One-Hot Encoding creates 100 features, whereas Binary Encoding would only create $\text{ceil}(\log_2(100)) = 7$ features.

Binary Encoding

- **Uso:** Ahorra memoria en tareas de texto (NLP) de alta complejidad.
- **Ventajas:** Reduce dimensiones y es mucho más ligero que el one-hot encoding.
- **Desventajas:** Implementación más compleja; exige controlar bien los valores nulos.




Binary Encoding

Integer Mapping: First, the unique categories are assigned integer values, starting from 1 (or sometimes 0).

Binary Conversion: Each integer is then converted into its binary representation. The number of binary digits (bits) needed is determined by the largest integer assigned.

Splitting into Columns: Finally, the binary strings are split into individual columns. Each position in the binary string becomes a new numerical feature.



Binary Encoding (Angela)

Se ennumeran las categorías para convertirlas en binario y cada bit se coloca en una columna diferente.

numero asignado


ID	Furniture	Furniture_0	Furniture_1
1	Chair	0	0
2	Table	0	1
3	Desk	1	0
4	Sofa	1	1
5	Sofa	1	1

bits

- El número de nuevas características crece logarítmicamente con el número de categorías.
 - Por ejemplo, si tiene 50 categorías, la codificación binaria solo generará 6 columnas (ya que $\log_2(50) \approx 6$).
- Para variables categóricas de alta cardinalidad, la codificación binaria es mucho más eficiente.

¿Qué es?

El análisis de componentes principales (PCA – Principal Component Analysis) es una técnica estadística y de machine learning que sirve para reducir la cantidad de variables de un conjunto de datos conservando la cantidad mayor posible de información (IBM, 2023).




Eigenfaces for recognition

Matthew Turk y Alex Pentland (1991)

Los autores proponen un método para que una computadora reconozca rostros humanos de forma rápida y relativamente simple, sin necesidad de modelar geometría 3D ni detectar características específicas (ojos, nariz, boca) de forma manual.

Cómo funciona para reconocimiento facial


- **Eigenfaces** (eigenvectors): Extraen los patrones de mayor variación entre fotos para crear los "moldes base" del face space.
- **Eigenvalues** : Califican la importancia de cada eigenface para conservar solo las más relevantes y reducir drásticamente la información.
- **Weight vectors** : Miden cuánto aporta cada eigenface a una cara específica, reduciendo miles de píxeles a una "receta" de pocos números.
- **Clasificación y face space** : Comparan esa "receta" contra las guardadas para identificar a la persona y verifican si la imagen realmente es un rostro.



Ejemplo

Digamos que tenemos una base de datos de todos en el salón, pero en lugar de guardar estas fotos de miles de píxeles de información, se pasa por el algoritmo de PCA para extraer estos eigenfaces. De esta manera no se guardan las fotos pesadas, sino el vector de peso de cada persona.

De esta manera, cada vez que alguien quiera probar un rostro, este comparará el vector de peso de este con los candidatos y tratará de predecir cual es el correcto



PCA

Principal Component Analysis

Juan Manuel Sandoval

Angela Aguilar

Diego Lopez

Rhamsés Orozco

¿Qué es?

El análisis de componentes principales (PCA – Principal Component Analysis) es una técnica estadística y de machine learning que sirve para reducir la cantidad de variables de un conjunto de datos conservando la cantidad mayor posible de información (IBM, 2023).

